Regression Analysis

请于 3 月 29 日前，将作业命名为学号+姓名+第一次作业发送至助教邮箱：
zhouziyu@mail.ustc.edu.cn

1、Dataset
该数据为混凝土抗压强度数据，共 1030 实例。8 输入变量，1 输出变量。
Columns:
Cement (component 1) ：kg in a m^3 mixture -- Input Variable
Blast Furnace Slag (component 2)：kg in a m^3 mixture -- Input Variable
Fly Ash (component 3)：kg in a m^3 mixture -- Input Variable
Water (component 4)：kg in a m^3 mixture -- Input Variable
Superplasticizer (component 5)：kg in a m^3 mixture -- Input Variable
Coarse Aggregate (component 6)：kg in a m^3 mixture -- Input Variable
Fine Aggregate (component 7)：kg in a m^3 mixture -- Input Variable
Age：Day (1~365) -- Input Variable
Concrete compressive strength：MPa -- Output Variable
2、Methods
1）我们的数据集中共有 8 个输入特征。一般而言，我们可以选择相关性更高的特征，以获得更好的结果。为此可以使用相关性分析或主成分分析等机器学习方法挑选数据集中的主要特征，以下列举了一些可能使用到的分析方法：
a) 相关性分析：通过计算各个特征与混凝土强度之间的相关性，选择与强度具有较高相关性的特征作为主要特征。
b) 主成分分析：将原始特征进行降维，提取能够解释大部分数据方差的主成分作为主要特征。

2) 推荐的方法：上课时讲到的线性回归或者构建神经网络。
下面以神经网络方法为例阐述具体的操作过程：
a) 数据准备：将数据集的前 80%作为训练集，后 20%作为测试集。
b) 数据预处理：对训练集和测试集的特征进行预处理（如：对缺失值进行处理），确保输入数据有相同的维度。
c) 神经网络构建：在 Python 中使用 Pytorch 等神经网络框架构建一个适合回归问题的神经网络模型，包括输入层、隐藏层和输出层。可以选择使用多个隐藏层和不同的激活函数测试效果。
d) 模型训练：使用训练集对神经网络模型进行训练，通过反向传播算法更新权重和偏置。
e) 模型测试和评估：使用测试集对训练好的神经网络模型进行测试，计算预测值与实际值之间的均方误差作为评价指标。同时，可以通过测试集的 target 与神经网络模型输出的 output，进行绘图，将神经网络模型的性能进行可视化。